

PIPELINE DETEKSI ANOMALI TRANSAKSI MENGUNAKAN APACHE SPARK, ISOLATION FOREST, POSTGRESQL, MONGODB, DAN DASHBOARD STREAMLIT

Kelompok 12 PA 3 :

- 11423003 : Samuel Rizki Sinambela
- 11423010 : Agatha C. S. Siahaan
- 11423025 : Yos Ivan Sirait
- 11423028 : Grace Advryanti Tampubolon
- 11423054 : Natan Obet Nego Hutahaeen

LATAR BELAKANG PROYEK

Perkembangan e-commerce dan retail digital telah menghasilkan volume data transaksi yang sangat besar. Setiap hari, jutaan transaksi terjadi secara online, menciptakan tantangan baru dalam pengelolaan dan analisis data. Dalam konteks ini, kemampuan untuk memproses dan menganalisis data secara real-time menjadi kebutuhan kritis bagi bisnis retail modern.

Deteksi transaksi abnormal menjadi sangat penting untuk mengurangi risiko fraud dan kerugian finansial. Proyek ini berfokus pada pembangunan pipeline Big Data end-to-end menggunakan teknologi mutakhir seperti Apache Spark, Isolation Forest, PostgreSQL, MongoDB, dan dashboard Streamlit untuk mengidentifikasi anomali transaksi secara efektif.



RUMUSAN MASALAH

01

Pipeline Data Besar

Bagaimana membuat pipeline data retail untuk data besar dengan kualitas terjaga dan proses yang efisien?

02

Fitur Deteksi Anomali

Bagaimana menghasilkan fitur yang efektif untuk deteksi anomali transaksi fraud?

03

Penyimpanan Database

Bagaimana menyimpan hasil analisis ke database yang dapat diakses oleh dashboard secara real-time?

04

Visualisasi Metrik

Bagaimana menampilkan metrik dan insight bisnis secara jelas melalui dashboard interaktif?

TUJUAN PROYEK

01

Pipeline End-to-End

Membangun pipeline Big Data end-to-end yang terintegrasi dari data mentah hingga insight bisnis yang actionable

02

Feature Engineering

Implementasi feature engineering untuk menghasilkan variabel numerik yang efektif bagi model deteksi anomali

03

Model Isolation Forest

Penerapan model Isolation Forest untuk mendeteksi transaksi abnormal secara akurat dan efisien

04

Database & Dashboard

Penyimpanan hasil di PostgreSQL dan MongoDB serta penyajian dashboard visual interaktif dengan Streamlit

KARAKTERISTIK BIG DATA

01

Volume

Dataset besar memerlukan Apache Spark untuk pemrosesan data yang efisien dan skalabel

02

Velocity

Data masuk dengan cepat, membutuhkan pipeline otomatis untuk pemrosesan real-time

03

Variety

Data beragam meliputi numerik, teks, tanggal, dan kategori yang perlu diintegrasikan

04

Veracity & Value

Kualitas data penting untuk akurasi model, menghasilkan insight bisnis dan deteksi fraud

TEKNOLOGI YANG DIGUNAKAN

01

Apache Spark & PySpark

Framework pemrosesan data besar terdistribusi untuk menangani volume data retail yang masif dengan performa tinggi dan skalabilitas.

02

Isolation Forest

Algoritma machine learning non-parametrik untuk deteksi anomali dengan mengisolasi titik data abnormal secara efektif.

03

PostgreSQL & MongoDB

Kombinasi database relasional untuk query SQL dan database dokumen untuk penyimpanan fleksibel hasil anomali.

04

Streamlit & Plotly

Platform visualisasi interaktif untuk membangun dashboard real-time yang menampilkan metrik dan insight bisnis.

DATASET DAN KOLOM UTAMA

Sumber Data:

Dataset yang digunakan adalah online_retail.csv, berisi data transaksi retail online dari perusahaan e-commerce berbasis UK. Dataset ini mencakup periode transaksi selama beberapa tahun dengan ratusan ribu record yang memerlukan pemrosesan Big Data.

Karakteristik Data:

- Terdapat duplikat yang perlu dibersihkan
- Nilai negatif pada Quantity menandakan retur
- Beberapa tipe data memerlukan konversi
- Missing values pada CustomerID

Kolom Utama Dataset:

- InvoiceNo: Nomor faktur transaksi
- StockCode: Kode produk unik
- Description: Deskripsi produk
- Quantity: Jumlah item dibeli
- InvoiceDate: Tanggal dan waktu transaksi
- UnitPrice: Harga per unit produk
- CustomerID: ID pelanggan
- Country: Negara pelanggan
- TotalPrice: Total harga ($\text{Quantity} \times \text{UnitPrice}$)



ARSITEKTUR SISTEM

PIPELINE ETL BIG DATA

Pipeline data dimulai dari file CSV mentah yang diproses menggunakan Apache Spark untuk pembersihan data. Data yang sudah bersih kemudian melalui tahap feature engineering untuk menghasilkan variabel-variabel baru yang relevan untuk analisis.

Selanjutnya, model Isolation Forest diterapkan untuk deteksi anomali. Hasil akhir disimpan ke PostgreSQL dan MongoDB, lalu divisualisasikan melalui dashboard Streamlit yang interaktif.



PROSES DATA CLEANING DENGAN PYSPARK

01

EDA & Quality Assessment

Eksplorasi data awal untuk memahami struktur, distribusi, dan kualitas dataset. Identifikasi pola, outlier, dan potensi masalah data.

02

Handle Missing & Invalid

Menangani nilai null, data duplikat, dan nilai negatif pada Quantity/UnitPrice. Identifikasi transaksi retur berdasarkan InvoiceNo.

03

Konversi Tipe Data

Konversi InvoiceDate ke timestamp, CustomerID ke integer, dan hitung kolom TotalPrice dari Quantity × UnitPrice.

04

Simpan ke Parquet

Hasil data bersih disimpan dalam format Apache Parquet untuk efisiensi penyimpanan dan kecepatan pemrosesan selanjutnya.

FEATURE ENGINEERING

01

Variabel Waktu

Ekstraksi fitur temporal: Hour, Day, MonthNum, WeekdayNum, dan Month dari InvoiceDate untuk analisis pola transaksi berdasarkan waktu.

02

RevenueCategory

Kategorisasi transaksi berdasarkan TotalPrice menjadi kelompok revenue (Low, Medium, High) untuk segmentasi analisis bisnis.

03


Country Encoding

Transformasi kolom Country menggunakan StringIndexer untuk mengkonversi data kategorikal menjadi numerik yang dapat diproses model.

04

Agregasi Customer

Fitur agregat pelanggan: ProductFrequency, AvgCustomerSpend, CustomerFrequency, CustomerTotalQty, dan CustomerPriceStd.



INTEGRASI DATABASE POSTGRESQL & MONGODB

POSTGRESQL

Database relasional untuk menyimpan tabel transaksi lengkap dengan struktur terorganisir. Mendukung SQL query kompleks untuk analisis data, join antar tabel, dan agregasi. Ideal untuk data terstruktur dengan skema tetap dan kebutuhan integritas data tinggi.

MONGODB

Database dokumen non-relasional untuk menyimpan hasil deteksi anomali dalam format JSON-like yang fleksibel. Cocok untuk data semi-terstruktur dan skema dinamis. Sinkronisasi data dan cross-check jumlah baris/dokumen memastikan konsistensi antar database.

MODEL DETEKSI ANOMALI ISOLATION FOREST

Isolation Forest adalah algoritma machine learning non-parametrik yang bekerja dengan prinsip isolasi titik data abnormal. Model ini efektif untuk mendeteksi anomali karena titik data yang tidak biasa cenderung lebih mudah diisolasi dibandingkan data normal. Algoritma membangun pohon keputusan secara acak dan mengukur panjang jalur untuk mengisolasi setiap titik data.

Model diterapkan pada fitur numerik hasil feature engineering seperti Quantity, UnitPrice, TotalPrice, dan agregasi customer. Output berupa label anomali (1 untuk anomali, 0 untuk normal) yang disimpan ke PostgreSQL dan MongoDB untuk analisis dan visualisasi dashboard.





HASIL DATA CLEANING & FEATURE ENGINEERING

DATA AWAL

Jumlah data awal yang diproses mencapai 397,884 baris transaksi dari dataset `online_retail.csv`. Data mentah ini mengandung duplikat, nilai negatif, dan memerlukan konversi tipe data sebelum dapat dianalisis lebih lanjut.

OUTPUT PIPELINE

Setelah proses feature engineering, dataset memiliki 21 kolom fitur lengkap. Hasil disimpan dalam format Apache Parquet: `cleaned_data` (data bersih) dan `featured_data` (data dengan fitur tambahan) untuk efisiensi penyimpanan dan pemrosesan.



STATISTIK ANOMALI

TOTAL TRANSAKSI

Jumlah total transaksi yang diproses dalam pipeline: 397,884 baris data. Setelah penerapan model Isolation Forest, terdeteksi 7,767 transaksi anomali (~1.95% dari total). Tingkat deteksi ini menunjukkan model bekerja dengan presisi tinggi.

CATATAN SINKRONISASI

Perbedaan jumlah anomali pada dashboard dapat terjadi karena status sinkronisasi MongoDB yang belum selesai atau perbedaan waktu query antara PostgreSQL dan MongoDB. Cross-check berkala diperlukan untuk memastikan konsistensi data.

INSIGHT BISNIS UTAMA

01

Total Revenue & AOV

Analisis total pendapatan keseluruhan dan Average Order Value (AOV) untuk mengukur performa bisnis retail secara agregat.

02

Distribusi Geografis

Pemetaan sebaran anomali transaksi berdasarkan negara untuk identifikasi wilayah dengan risiko fraud tinggi.

03

Top 10 Produk


Identifikasi produk dengan volume penjualan tertinggi untuk fokus strategi inventory dan marketing.

04


Pola Waktu Penjualan

Analisis jam sibuk dan hari puncak transaksi untuk optimasi operasional dan deteksi anomali temporal.

VISUALISASI DASHBOARD STREAMLIT



VISUALISASI DASHBOARD STREAMLIT



KESIMPULAN DAN SARAN

01

Pipeline End-to-End

Pipeline berhasil membangun proses lengkap dari data mentah hingga insight bisnis yang actionable

02

Isolation Forest Efektif

Model Isolation Forest efektif mendeteksi anomali transaksi retail dengan akurasi tinggi

03

Integrasi Database

Database relasional PostgreSQL dan non-relasional MongoDB berhasil diintegrasikan dengan baik

04

Dashboard Interaktif

Dashboard Streamlit mempermudah pemantauan real-time dan pengambilan keputusan bisnis

TERIMA KASIH & TANYA JAWAB

Terima kasih telah menyimak presentasi Laporan Proyek Big Data Retail ini. Kami sangat menghargai perhatian dan waktu Anda. Silakan ajukan pertanyaan mengenai pipeline deteksi anomali, implementasi teknologi, atau hasil analisis yang telah kami sampaikan. Tim kami siap berdiskusi lebih lanjut.

